

# Onde a Ciência de Dados Começa?

## "Onde a ciência de dados começa?"

Antes de qualquer análise ou tomada de decisão baseada em dados, precisamos ter **dados de alta qualidade**. A qualidade dos dados é o alicerce para todo o processo de ciência de dados.

**Lembre-se:** Dados de baixa qualidade levam a análises imprecisas e decisões equivocadas, independentemente da sofisticação dos algoritmos utilizados.

## Conceitos Fundamentais

### Dados Primários

Coletados diretamente para um objetivo específico

Ex: Pesquisas, entrevistas, experimentos

### Dados Secundários

Já existentes, coletados por terceiros

Ex: Bases governamentais, relatórios, redes sociais



# Fontes Primárias vs. Secundárias

## Fontes Primárias

Dados coletados diretamente para um objetivo específico.

**Exemplos:** Pesquisas, experimentos, entrevistas, observações diretas.

### Vantagens

Controle total sobre a coleta

Dados específicos para o objetivo

Maior confiabilidade

### Desvantagens

Processo caro e demorado

Requer expertise em coleta

Amostra geralmente menor

## Fontes Secundárias

Dados já existentes, coletados por terceiros para outros propósitos.

**Exemplos:** Bases governamentais (IBGE, DataSUS), relatórios, redes sociais.

### Vantagens

Acesso rápido e econômico

Grande volume de dados

Séries históricas disponíveis

### Desvantagens

Qualidade e relevância limitadas

Falta de controle sobre a coleta

Possível desatualização



# Fontes Internas vs. Externas

## Fontes Internas

Dados gerados dentro da própria organização durante suas operações regulares.

**Características:** Maior controle, acesso facilitado, específicos para o negócio.

### Exemplos de Fontes Internas

- Registros de vendas e transações
- Dados de RH (funcionários, salários)
- Registros de produção e estoque
- Dados de CRM e atendimento ao cliente
- Logs de sistemas e aplicações
- Pesquisas internas com funcionários

*Vantagem principal: Dados específicos para o contexto da organização, com acesso direto e controle sobre a qualidade.*

## Fontes Externas

Dados provenientes de fora da organização, coletados e disponibilizados por terceiros.

**Características:** Maior volume, perspectiva externa, complementam dados internos.


### Exemplos de Fontes Externas

- Dados governamentais (dados.gov.br, IBGE)
- Dados de saúde pública (DataSUS)
- Dados econômicos (Banco Central)
- Redes sociais e mídia online
- Pesquisas de mercado de terceiros
- Dados de parceiros comerciais

*Vantagem principal: Fornecem contexto mais amplo e permitem comparações com o mercado e tendências externas.*



## Etapas da análise de dados



# Atividade Prática 1: Mapeamento e Seleção de Fontes

**Objetivo:** Desenvolver a capacidade de identificar, avaliar e selecionar fontes de dados adequadas para um problema específico.

## Instruções

### 1 Escolha do Tema

Cada escolherá um dos seguintes temas:

Hábitos de Consumo	Mobilidade Urbana
Saúde Pública	Educação Digital

### 2 Brainstorm de Fontes

Cada um deve listar pelo menos:

- 2 fontes de dados primárias que poderiam usar para o tema
- 2 fontes de dados secundárias que poderiam usar para o tema

*Exemplo para "Saúde Pública": Uma fonte primária seria uma pesquisa com a comunidade local e uma secundária seria o DataSUS.*

### 3 Justificativa

Para cada fonte listada, o grupo deve justificar:

- Relevância para o tema (por que esta fonte é útil?)
- Confiabilidade da fonte (como avaliar sua qualidade?)
- Possíveis limitações ou vieses da fonte
- Fontes selecionadas e justificativas
- Critérios utilizados para avaliar a qualidade das fontes
- Desafios encontrados durante o processo de seleção

# Atividade Prática 2: Simulação de Coleta Experimental

**Objetivo:** Realizar uma coleta de dados primários através de um experimento simples utilizando o Google Forms.

## Passo a Passo

### 1 Criação do Experimento

Cada grupo deve criar um experimento simples que possa ser realizado em sala de aula.

#### Exemplo:

"Qual o tempo médio que os alunos levam para responder a uma pergunta de múltipla escolha no Google Forms?"

2

### Criação do Formulário

Utilize o Google Forms para criar um formulário que cole os dados necessários:

Acesse [forms.google.com](https://forms.google.com)

Crie um novo formulário

Adicione perguntas relevantes para o experimento

Configure as opções de coleta de respostas

3

### Aplicação e Coleta

Os grupos aplicam o formulário entre si e coletam os dados:

Compartilhe o link do formulário com os outros grupos

Cada aluno deve responder aos formulários dos outros grupos

Acompanhe as respostas em tempo real na aba "Respostas" do Google Forms

#### Dicas para um bom formulário:

Mantenha o formulário curto e objetivo

Use perguntas claras e diretas

Evite perguntas tendenciosas

Teste o formulário antes de aplicar

Inclua instruções claras no início

# Atividade Prática 3: Limpeza e Tratamento dos Dados

**Objetivo:** Trabalhar com os dados coletados na atividade anterior, identificando e corrigindo erros comuns.

## Passo a Passo (Google Sheets/Excel)



### 1 Transferência dos Dados

Exporte os dados do Google Forms para uma planilha

Verifique se todos os campos foram transferidos corretamente

### 2 Identificação de Erros

#### Valores Nulos

Campos deixados em branco pelos respondentes

*Dica: Use filtros para identificar células vazias*

#### Duplicatas

Respostas enviadas mais de uma vez

*Dica: Use "Remover duplicatas" no menu Dados*

#### Inconsistências

Formatos diferentes para o mesmo tipo de resposta

*Ex: "sim", "s", "SIM" para a mesma pergunta*

#### Valores Atípicos

Respostas que fogem muito do padrão esperado

*Ex: Tempo de resposta de 300 segundos quando a média é 30*

### 3 Limpeza dos Dados

Corrija os erros identificados manualmente ou usando fórmulas

Padronize formatos (datas, números, textos)

Documente todas as alterações feitas

### Fixação

Após a limpeza, discuta com a turma:

Quais erros foram mais comuns?  
Como esses erros poderiam afetar análises futuras?

Quais estratégias poderiam prevenir esses erros na coleta?

# Comandos Python/Pandas para Limpeza de Dados

O Python, com a biblioteca Pandas, oferece ferramentas poderosas para automatizar a limpeza e o tratamento de dados. Abaixo estão alguns comandos essenciais:

## 1. Identificação de Valores Nulos

```
# Verificar valores nulos em todo o DataFrame  
df.isnull().sum()  
  
nome 0  
idade 2  
cidade 1  
dtype: int64
```

## 2. Remoção de Linhas com Valores Nulos

```
# Remover linhas que contêm valores nulos  
df_limpo = df.dropna()  
  
# Remover linhas com valores nulos apenas em colunas específicas  
df_limpo = df.dropna(subset=['idade', 'cidade'])
```

## 3. Preenchimento de Valores Nulos

```
# Preencher valores nulos com um valor específico  
df['idade'] = df['idade'].fillna(0)  
  
# Preencher com a média da coluna  
df['idade'] = df['idade'].fillna(df['idade'].mean())
```

## 4. Remoção de Duplicatas

```
# Identificar duplicatas  
df.duplicated().sum()  
  
# Remover linhas duplicadas  
df_sem_duplicatas = df.drop_duplicates()
```

## 5. Tratamento de Inconsistências

```
# Padronizar texto (converter para minúsculas)  
df['cidade'] = df['cidade'].str.lower()  
  
# Remover espaços extras  
df['nome'] = df['nome'].str.strip()
```

# Atividade Prática 4: Discussão de Casos Éticos e LGPD

**Objetivo:** Desenvolver o pensamento crítico sobre questões éticas relacionadas à coleta e uso de dados, considerando a Lei Geral de Proteção de Dados (LGPD).

## Caso A: Marketing Digital e Geolocalização

Uma empresa de marketing digital utiliza dados de localização de clientes para enviar publicidade direcionada sem consentimento explícito. Os usuários recebem notificações de ofertas ao passar próximo a lojas parceiras, sem terem sido informados sobre esse tipo de rastreamento.

## Caso B: Vazamento em Sistema de Saúde

Um sistema de saúde utiliza dados anônimos de pacientes para pesquisa médica. No entanto, uma falha de segurança permite que terceiros consigam cruzar informações e identificar pacientes específicos, expondo condições médicas sensíveis.

## Perguntas para Discussão

### É permitido coletar esse dado?

Analise se há base legal para a coleta segundo a LGPD.

### Qual a base legal (LGPD) para essa coleta?

Identifique qual das bases legais previstas na LGPD poderia justificar (ou não) a coleta.

### Como garantir a privacidade e o anonimato?

Proponha medidas técnicas e organizacionais para proteger os dados.

# LGPD e Proteção de Dados

**Objetivo principal:** Proteger os direitos fundamentais de liberdade e de privacidade e o livre desenvolvimento da personalidade da pessoa natural.

## Bases Legais para Coleta de Dados

A LGPD estabelece que o tratamento de dados pessoais só pode ocorrer nas seguintes hipóteses:

### Consentimento

Manifestação livre, informada e inequívoca do titular

### Obrigação Legal

Cumprimento de obrigação legal ou regulatória

### Execução de Contrato

Necessário para execução de contrato com o titular

### Interesse Legítimo

Atender aos interesses legítimos do controlador

### Proteção da Vida

Proteção da vida ou da incolumidade física

### Tutela da Saúde

Tutela da saúde, em procedimento realizado por profissionais



## Princípios da LGPD

Finalidade

Adequação

Necessidade

Livre acesso

Qualidade dos dados

Transparência

Segurança

Prevenção

Não discriminação

Responsabilização

## Implicações para Coleta de Dados

Obter consentimento explícito quando necessário

Informar claramente a finalidade da coleta

Coletar apenas dados necessários (minimização)

Garantir a segurança dos dados coletados

Permitir acesso, correção e exclusão pelos titulares

Documentar todo o processo de tratamento

# Avaliação da Qualidade dos Dados

A qualidade dos dados é fundamental para garantir análises confiáveis e decisões acertadas. Dados de baixa qualidade podem levar a conclusões equivocadas, independentemente da sofisticação das técnicas de análise utilizadas.

**"Garbage in, garbage out"** - Princípio fundamental da ciência de dados que ressalta a importância da qualidade dos dados de entrada.

## Critérios de Qualidade dos Dados

### Precisão

Os dados representam corretamente a realidade que pretendem descrever? Estão livres de erros?

### Completude

Os dados contêm todas as informações necessárias? Existem valores ausentes ou campos incompletos?

### Consistência

Os dados são coerentes entre si? Existem contradições ou informações conflitantes?

### Relevância

Os dados são úteis para o problema que se pretende resolver? Atendem às necessidades da análise?

## Impacto da Qualidade dos Dados

Decisões de negócio mais acertadas

Redução de custos operacionais

Maior confiança nos resultados analíticos

Melhor experiência do cliente

Conformidade com regulamentações

### Comparação de Qualidade de Dados



# Encerramento e Próximos Passos

## Principais Aprendizados

A coleta e limpeza de dados são etapas fundamentais para análises confiáveis

A escolha das fontes de dados deve ser baseada no problema a ser resolvido

Dados primários oferecem controle, mas dados secundários são mais acessíveis

A qualidade dos dados impacta diretamente a qualidade das análises

A ética e a LGPD devem ser consideradas em todo o processo de coleta

**A coleta e a limpeza de dados não são apenas etapas técnicas, mas processos que exigem responsabilidade, ética e atenção aos detalhes.**

### Compreendendo a importância da qualidade dos dados



### Processo de Ciência de Dados

